



MATERIAL DE APOYO - ACTIVIDAD 1

Mi Primer Cuaderno de Inteligencia Artificial en Google Colab

Curso: Aplicacion de Apps de IA | SENA Tolima | Febrero 2026

1. OBJETIVOS DE LA ACTIVIDAD

Al finalizar esta actividad, el estudiante estara en capacidad de:

1. Familiarizarse con el entorno de Google Colaboratory (Colab).
2. Conocer y aplicar el asistente de codigo con IA integrado en Colab: Gemini.
3. Cargar un dataset, realizar un EDA (Análisis Exploratorio de Datos) y visualizar resultados.
4. Entrenar un modelo de Machine Learning y evaluar su desempeño con una matriz de confusion.

RESULTADO ESPERADO: Modelo entrenado guardado como archivo modelo_iris.h5 del dataset Iris.

2. INTRODUCCION A GOOGLE COLAB

Google Colaboratory (Colab) es una plataforma gratuita en la nube que permite escribir y ejecutar codigo Python directamente desde el navegador, sin instalar nada en tu computador.

2.1 Como acceder a Colab

1. Abre tu navegador y ve a: colab.research.google.com
2. Inicia sesion con tu cuenta de Google.
3. Haz clic en '+ Nuevo cuaderno' para crear uno nuevo, o abre el cuaderno compartido por el instructor.

2.2 Partes de un cuaderno Colab

- Celdas de texto (Markdown): Contienen instrucciones, titulos y explicaciones. Se muestran en gris/blanco.
- Celdas de codigo (Code): Contienen instrucciones en Python que puedes ejecutar. Se muestran con fondo mas oscuro.
- Boton de ejecucion (▶): Aparece a la izquierda de cada celda de codigo. Haz clic para ejecutarla.
- Resultado (Output): Aparece justo debajo de la celda ejecutada.

TIP: También puedes ejecutar una celda presionando Shift + Enter en tu teclado.

3. ASISTENTE DE CODIGO CON IA: GEMINI EN COLAB

Google Colab tiene integrado un asistente de Inteligencia Artificial llamado Gemini que te ayuda a generar, explicar y corregir codigo automaticamente.

3.1 Como activar y usar Gemini

1. En la barra superior del cuaderno, busca el icono de estrella (★) o el boton 'Gemini'.
2. Haz clic y se abra un panel de chat lateral.
3. Escribe en lenguaje natural lo que necesitas. Ejemplo: 'Genera un histograma de la columna SepalLength'.
4. Gemini sugerira codigo que puedes insertar directamente en una celda.

Regional Tolima - Centro de Industria y Construcción
Cra. 45 Sur #1255 141- Sector, Ibagué, Tolima



IMPORTANTE: En esta actividad, el cuaderno ya está diligenciado. Tu tarea es EJECUTAR cada celda en orden y ANALIZAR los resultados que obtienes.

4. GUIA PASO A PASO: EJECUCION DEL CUADERNO

PASO 1 - Saludo Inicial y Entorno

Las primeras celdas son de introducción. Incluyen el título del cuaderno y dos ejercicios básicos de Python:

```
print("Hola Mundo")
nombre = input("Digite su nombre")
print("Su nombre ", nombre)
```

Al ejecutar la celda del input, el programa te pedirá que escribas tu nombre. Dígitalo y presiona Enter.

QUE ANALIZAR: Observa como Python puede pedir datos al usuario con `input()` y mostrar resultados con `print()`.

PASO 2 - Descarga del Dataset Iris

Se utiliza la librería `kagglehub` para descargar automáticamente el famoso dataset Iris desde Kaggle.

```
import kagglehub
path = kagglehub.dataset_download("uciml/iris")
print("Path to dataset files:", path)
```

El dataset Iris contiene 150 muestras de flores de 3 especies diferentes (Setosa, Versicolor, Virginica), con 4 características cada una: longitud y ancho del sépalo y pétalo.

QUE ANALIZAR: Observa la ruta (`path`) donde se descargó el archivo. Cada vez que ejecutes puede variar.

PASO 3 - EDA: Carga y Exploración de Datos

El EDA (Exploratory Data Analysis) nos permite entender los datos antes de entrenar un modelo. Se ejecutan tres celdas importantes:

a) Carga del archivo CSV con pandas:

```
import pandas as pd
iris_df = pd.read_csv(f"{path}/Iris.csv")
print(iris_df.head())
```

b) Información básica del dataset:

```
iris_df.info()      # Tipos de datos y valores nulos
iris_df.describe()  # Estadísticas descriptivas
```

QUE ANALIZAR: Cuántas filas y columnas tiene el dataset? Hay valores nulos? ¿Cuál es el rango de cada columna?

PASO 4 - EDA: Visualización de Distribuciones (Histogramas)

Se generan histogramas para cada variable numérica con `matplotlib`. Un histograma muestra como se distribuyen los valores de una variable.

Regional Tolima - Centro de Industria y Construcción
Cra. 45 Sur #1255 141- Sector, Ibagué, Tolima



QUE ANALIZAR: Las variables de petalo (PetalLength, PetalWidth) muestran una distribución bimodal (dos picos). Esto sugiere que hay dos grupos claramente separados, lo que es una pista de que el modelo podrá distinguir las especies.

PASO 5 - EDA: Pair Plot (Relaciones entre Variables)

Se genera un pair plot usando seaborn, que muestra la relación entre todos los pares de variables, coloreados por especie.

QUE ANALIZAR: La especie Iris-setosa (primer color) está completamente separada de las otras dos. Las especies Versicolor y Virginica se superponen un poco en algunas variables, pero son separables especialmente por longitud y ancho del petalo.

PASO 6 - EDA: Box Plots (Detección de Outliers)

Los box plots muestran la distribución de cada variable por especie e identifican valores atípicos (outliers), representados como puntos fuera de las 'cajas'.

QUE ANALIZAR: Observa que la variable SepalWidthCm de Iris-setosa muestra algunos outliers. Los valores de PetalLength y PetalWidth son los más discriminativos entre especies.

PASO 7 - Entrenamiento del Modelo de Clasificación

Esta es la celda principal donde se construye, entrena y evalúa el modelo de red neuronal. A continuación se explica cada parte:

7.1 Selección de Características

Se usan las 4 columnas numéricas como entradas (X): SepalLengthCm, SepalWidthCm, PetalLengthCm, PetalWidthCm. La variable objetivo (y) es la columna Species.

7.2 División del Dataset: 60% - 20% - 20%

```
X_train (60%): datos para entrenar el modelo
X_val    (20%): datos para ajustar el modelo durante el entrenamiento
X_test   (20%): datos para evaluar el desempeño final
```

7.3 Preprocesamiento

- StandardScaler: Normaliza los datos para que tengan media 0 y desviación estándar 1.
- LabelEncoder + to_categorical: Convierte las etiquetas de texto (nombres de especies) a formato numérico one-hot.

7.4 Arquitectura del Modelo (Red Neuronal)

```
Capa 1: Dense(10, activation='relu') -> 10 neuronas, aprendizaje
Capa 2: Dense(10, activation='relu') -> 10 neuronas, mas aprendizaje
Capa 3: Dense(3, activation='softmax') -> 3 neuronas, una por especie
```

La función softmax en la última capa convierte la salida en probabilidades. La especie con mayor probabilidad es la predicción del modelo.

7.5 Entrenamiento

```
model.fit(..., epochs=50, batch_size=8)
```

El modelo se entrena durante 50 épocas (pasadas completas por los datos de entrenamiento), actualizando sus pesos para minimizar el error.



QUE ANALIZAR: El modelo debe alcanzar una precision (accuracy) alta en los datos de prueba (normalmente >90% para el dataset Iris). Observa el reporte de clasificacion que incluye precision, recall y F1-score por especie.

PASO 8 - Matriz de Confusion

La matriz de confusion es una tabla que muestra cuantas predicciones fueron correctas e incorrectas para cada clase.

Como leer la matriz:

- Los valores en la DIAGONAL PRINCIPAL son las predicciones CORRECTAS.
- Los valores FUERA de la diagonal son errores (confusion entre especies).
- Filas = clases reales | Columnas = clases predichas.

Ejemplo de interpretacion: Si en la fila 'Iris-setosa' y columna 'Iris-setosa' hay un 10, significa que 10 flores setosa fueron clasificadas correctamente. Si en la fila 'Iris-versicolor' y columna 'Iris-virginica' hay un 1, significa que 1 versicolor fue confundida con virginica.

QUE ANALIZAR: Una buena matriz de confusion tiene valores altos en la diagonal y cercanos a cero fuera de ella. Iris-setosa suele ser clasificada perfectamente (100%) por su gran separacion en el espacio de caracteristicas.

PASO 9 - Guardar el Modelo (.h5)

Al finalizar el entrenamiento, el modelo se guarda en formato HDF5 (.h5), que es un formato estandar para guardar redes neuronales de TensorFlow/Keras.

```
model.save('modelo_iris.h5')
print("Modelo guardado como modelo_iris.h5")
```

Para descargar el archivo desde Colab:

1. En el panel izquierdo de Colab, haz clic en el icono de carpeta (📁).
2. Busca el archivo 'modelo_iris.h5'.
3. Haz clic derecho sobre el archivo y selecciona 'Descargar'.

NOTA: Los archivos en Colab se eliminan cuando la sesion se cierra. Descarga el modelo o guarda tu cuaderno en Google Drive antes de cerrar.

5. GLOSARIO DE CONCEPTOS CLAVE

Dataset: Conjunto de datos organizado en filas (muestras) y columnas (variables o caracteristicas).

EDA (Exploratory Data Analysis): Proceso de analisis inicial de datos para descubrir patrones, anomalias y relaciones.

Red Neuronal (Neural Network): Modelo de Machine Learning inspirado en el cerebro humano, compuesto por capas de 'neuronas' artificiales.

Epoch: Una pasada completa del algoritmo de entrenamiento por todo el dataset.

Accuracy (Precision): Porcentaje de predicciones correctas sobre el total. Un valor de 0.95 significa 95% de aciertos.

Overfitting: Cuando el modelo 'memoriza' los datos de entrenamiento pero falla en datos nuevos.

Regional Tolima - Centro de Industria y Construcción
Cra. 45 Sur #1255 141- Sector, Ibagué, Tolima



Softmax: Funcion matematica que convierte un vector de numeros en probabilidades que suman 1.

ReLU: Funcion de activacion popular en redes neuronales. Retorna el valor si es positivo, o 0 si es negativo.

6. LISTA DE VERIFICACION DE LA ACTIVIDAD

Marca cada punto a medida que completas la actividad:

- ☐ Abri el cuaderno en Google Colab correctamente.
- ☐ Ejecute la celda 'Hola Mundo' y la celda de input con mi nombre.
- ☐ Descargue exitosamente el dataset Iris con kagglehub.
- ☐ Ejecute el EDA y observe el head(), info() y describe().
- ☐ Visualice los histogramas de las 4 variables numericas.
- ☐ Genere el pair plot por especie y analice la separacion de clases.
- ☐ Observe los box plots e identifique posibles outliers.
- ☐ Ejecute el entrenamiento del modelo (puede tardar 1-2 minutos).
- ☐ Analice el reporte de clasificacion y la matriz de confusion.
- ☐ Descargue el archivo modelo_iris.h5 a mi computador.

7. PREGUNTAS DE REFLEXION

Responde en tu cuaderno o en el foro del curso:

1. Cual especie de Iris fue la mas facil de clasificar correctamente por el modelo? Por que crees que ocurre esto?
2. Que diferencia encuentras entre las distribuciones de las variables de sepalo (SepalLength, SepalWidth) y las de petalo (PetalLength, PetalWidth)?
3. Que pasaria si entrenamos el modelo solo con las variables de petalo? Mejoraria o empeoraria?
4. Para que sirve el archivo .h5 que guardamos? Menciona un caso de uso real.

Elaborado por:

Instructor | SENA - Regional Tolima

Aplicacion de Apps de Inteligencia Artificial | Febrero 2026

Regional Tolima - Centro de Industria y Construcción
Cra. 45 Sur #1255 141- Sector, Ibagué, Tolima